

MATRIZ DE COSTOS Y DECISIÓN TECNOLÓGICA

Documento de Arquitectura & Selección de Stack Técnico

1. RESUMEN DE LAS TECNOLOGÍAS UTILIZADAS

COMPONENTE	TECNOLOGÍA ELEGIDA	ALTERNATIVAS CONSIDERADAS	FUNCIÓN EN EL PROYECTO
Orquestación	n8n	Make	Ejecutar y coordinar todo el workflow.
Base de Datos / CRM	Airtable	Notion	Almacenar Leads, Interactions y Errores.
Motor de IA	OpenRouter	OpenAI / Claude	Analizar emails y generar respuesta.
Entrada	Gmail	Webhook / Formulario	Recibir consultas de potenciales clientes.
Notificación HITL	Telegram	Slack	Solicitar aprobación humana.
Salida	Gmail	Telegram / Slack	Enviar respuesta al cliente.

2. COMPARACIÓN DE COSTOS

Para la evaluación económica, se separa el costo de plataforma del costo variable por uso, evitando estimaciones arbitrarias sin un volumen definido de mensajes y tokens.

TECNOLOGÍA	MODELO DE COSTO	IMPACTO EN EL PROYECTO	EVALUACIÓN
n8n	Suscripción / ejecución según plan	Principalmente depende del volumen de workflows	★★★★★
Make	Suscripción basada en operaciones	Puede aumentar con workflows complejos	★★★★☆
Airtable	Plan gratuito / planes pagos	Depende del volumen de registros y funciones	★★★★★
Notion	Plan gratuito / planes pagos	Adecuado para documentación y bases simples	★★★★☆
OpenRouter	Pago por uso según modelo/tokens	Variable según cantidad de emails y modelo utilizado	★★★★★
OpenAI	Pago por uso según modelo/tokens	Variable según modelo y tokens	★★★★★
Claude	Pago por uso según modelo/tokens	Variable según modelo y tokens	★★★★★
Gmail	Servicio utilizado para email	No se agrega un costo específico al workflow	★★★★★
Telegram	Servicio utilizado para HITL	No se agrega un costo específico al workflow	★★★★★

3. DECISIÓN TECNOLÓGICA

Orquestación — n8n

Elección: [n8n](#)

Se seleccionó n8n como plataforma de automatización porque permite representar visualmente el flujo completo, integrar múltiples servicios, utilizar lógica condicional, manejar errores y construir procesos con intervención humana. Además, permite mayor control sobre la estructura del workflow y facilita la documentación técnica del proyecto.

Alternativa: Make.

Motivo de descarte: Make también permite construir automatizaciones complejas, pero para este proyecto n8n resulta más conveniente por su flexibilidad en la construcción del flujo, manejo de ramas y control de nodos.

Base de datos — Airtable

Elección: [Airtable](#)

Se seleccionó Airtable como CRM y base de memoria porque permite estructurar la información en tablas relacionadas y mantener separados los datos de Leads, Interactions y Errores. La estructura permite relacionar cada interacción con su correspondiente lead y conservar el historial necesario para que el agente de IA pueda analizar el contexto.

Alternativa: Notion.

Motivo de descarte: Notion es una alternativa válida para almacenar información estructurada, pero Airtable resulta más apropiado para este caso debido a su orientación hacia registros tabulares, relaciones y operaciones sobre datos.

Motor de IA — OpenRouter

Elección: [OpenRouter](#)

Se utilizó OpenRouter como capa de acceso al modelo de inteligencia artificial debido a que permite trabajar con diferentes modelos mediante una integración unificada. Esto facilita la evaluación de alternativas de modelos y permite adaptar el costo y capacidad del motor de IA según las necesidades del proyecto.

Alternativas: OpenAI y Claude.

Motivo: Ambos ofrecen modelos adecuados para procesamiento de lenguaje natural, pero OpenRouter permite mantener mayor flexibilidad para seleccionar el modelo utilizado sin modificar la arquitectura principal del workflow.

Canal de Human-in-the-loop — Telegram

Elección: [Telegram](#)

Telegram se utiliza para notificar al responsable cuando el AI Agent determina que una interacción requiere revisión humana. La persona puede aprobar o rechazar la respuesta antes de que el sistema envíe el mensaje al cliente.

Alternativa: Slack.

Motivo: Telegram permite implementar el circuito de aprobación de manera sencilla y cumple con el requisito de incorporar intervención humana antes de una acción crítica.

4. OPTIMIZACIÓN DE COSTOS DE IA

La arquitectura del workflow ha sido específicamente diseñada bajo criterios de eficiencia de costos computacionales y consumo de tokens:

1. Filtrado previo

El workflow primero determina si el email es relevante. Los mensajes que no corresponden al caso de uso no continúan hacia el procesamiento de IA, evitando consumo innecesario de recursos.

```
Email → ¿Es correo relevante? → NO → FIN
                                   ↓
                                   SÍ → AI Agent
```

2. Prevención de procesamiento duplicado

Antes de procesar el mensaje, n8n verifica el Gmail Message ID para evitar reanalizar interacciones previas.

```
Gmail Message ID → ¿Ya existe? → SÍ → FIN
                                   ↓
                                   NO → Procesar
```

3. Minimización del contexto enviado al modelo

El AI Agent recibe únicamente la información necesaria para realizar el análisis comercial. No se envían identificadores internos innecesarios de Airtable, lo que reduce el volumen de información procesada y mejora la protección de datos.

4. Structured Output Parser

El AI Agent utiliza un formato estructurado con campos definidos para garantizar salidas controladas:

```
categoria | intencion | prioridad | lead_score | requiere_revision | respuesta
```

5. Human-in-the-loop selectivo

No todas las interacciones requieren intervención humana. El workflow solamente solicita aprobación cuando **requiere_revision = TRUE**. Las interacciones que no requieren revisión siguen automáticamente hacia la respuesta.

5. FÓRMULA DE COSTO VARIABLE

Costo estimado de IA:

$$\text{Costo de IA} = (\text{tokens de entrada} \times \text{precio de entrada}) + (\text{tokens de salida} \times \text{precio de salida})$$

Costo total del proyecto:

$$\text{Costo operativo} = \text{costo de IA} + \text{costo de plataforma de automatización} + \text{costo de almacenamiento/CRM}$$

El costo real dependerá principalmente de:

- Cantidad de emails procesados.
- Cantidad de tokens por interacción.
- Modelo de IA seleccionado.
- Cantidad de ejecuciones del workflow.
- Plan utilizado en n8n.
- Volumen de registros almacenados.

6. MATRIZ FINAL DE DECISIÓN

COMPONENTE	ELEGIDO	ALTERNATIVA	COSTO	FLEXIBILIDAD	INTEGRACIÓN	DECISIÓN
Orquestación	n8n	Make	Medio/ variable	Alta	Alta	✓ Elegido

COMPONENTE	ELEGIDO	ALTERNATIVA	COSTO	FLEXIBILIDAD	INTEGRACIÓN	DECISIÓN
CRM / DB	Airtable	Notion	Gratis / planes pagos	Alta	Alta	✓ Elegido
IA	OpenRouter	OpenAI / Claude	Variable por uso	Muy alta	Alta	✓ Elegido
Email entrada	Gmail	Webhook	Sin costo adicional específico	Alta	Alta	✓ Elegido
HITL	Telegram	Slack	Sin costo adicional específico	Alta	Alta	✓ Elegido
Email salida	Gmail	Otros canales	Sin costo adicional específico	Alta	Alta	✓ Elegido

Criterios de Evaluación Utilizados:

Costo, flexibilidad, facilidad de integración, capacidad de automatización, escalabilidad y adecuación al caso de uso.

Declaración de Costo Operativo:

El costo operativo del sistema es variable y depende principalmente del volumen de ejecuciones, registros procesados y tokens consumidos por el modelo de IA. La arquitectura fue diseñada para minimizar costos mediante filtrado previo, prevención de duplicados, minimización de contexto y procesamiento selectivo mediante Human-in-the-loop.