

DOCUMENTO DE SEGURIDAD Y RESILIENCIA

Entregable Final: AI Sales & Customer Operations Agent

Proyecto:	AI Sales & Customer Operations Agent	Entorno:	n8n Cloud 2.36.7
Tecnologías:	n8n Cloud 2.36.7, Gmail, Airtable, OpenRouter, AI Agent de n8n, Structured Output Parser, Telegram		

13.1 Introducción

El presente documento constituye el entregable técnico-académico correspondiente a la dimensión de **Seguridad y Resiliencia** del proyecto *AI Sales & Customer Operations Agent*. El objetivo fundamental es detallar y demostrar el cumplimiento riguroso de los controles de protección de datos, tolerancia a fallos y supervisión humana integrados en el flujo de trabajo automatizado.

En el contexto de automatización empresarial impulsada por Inteligencia Artificial (IA), los aspectos de seguridad y resiliencia no representan características accesorias, sino requisitos operacionales críticos. La ejecución autónoma de acciones comerciales y operativas (como responder correos electrónicos a clientes) requiere barreras estrictas de contención que garanticen la integridad de los datos, prevengan comportamientos erráticos del modelo y aseguren que ninguna comunicación sensible sea emitida sin la debida revisión cuando la situación lo amerite. Este documento certifica la arquitectura implementada y probada objetivamente dentro del workflow.

13.2 Minimización de Datos

El principio de minimización de datos se implementa restringiendo estrictamente la información transmitida al nodo AI Agent a aquellos campos indispensables para realizar la evaluación comercial y la generación de respuestas.

El AI Agent procesa exclusivamente los siguientes campos contextuales:

- **Nombre:** Identificación contextual del remitente.
- **Email:** Dirección de correo del cliente.
- **Asunto:** Encabezado del mensaje para análisis del tema.
- **Mensaje:** Cuerpo principal de la consulta o requerimiento.
- **Fecha:** Marca temporal del mensaje para contexto cronológico.
- **Historial relevante del Lead:** Antecedentes de interacciones previas almacenados en el CRM (cuando el Lead existe).

Exclusión de identificadores internos: Los identificadores únicos del sistema generados por la plataforma n8n y la base de datos Airtable (IDs de registro, IDs de ejecución) no aportan valor semántico ni contextual para el razonamiento de la IA. En consecuencia, estos IDs internos fueron eliminados del prompt enviado al modelo de lenguaje. Dichos identificadores continúan siendo gestionados de manera interna e inclusiva por n8n para mantener la integridad referencial al momento de actualizar las tablas en Airtable.

La minimización de datos responde a dos objetivos fundamentales:

1. **Protección de estructura interna:** Evitar la exposición innecesaria de la arquitectura de datos e identificadores internos del sistema hacia modelos/proveedores externos.
2. **Eficiencia operativa y de cómputo:** Reducir la dimensión del contexto enviado, lo cual optimiza directamente el consumo de tokens por ejecución.

Tabla de Minimización de Datos

Dato	¿Se utiliza?	Motivo
Nombre	Sí	Identificación contextual
Email	Sí	Contexto de la interacción
Asunto	Sí	Análisis de la consulta
Mensaje	Sí	Análisis principal
Fecha	Sí	Contexto temporal
Historial relevante	Cuando corresponde	Contexto del Lead
IDs internos innecesarios	No	No son necesarios para el análisis

AI Agent y Salida Estructurada

La interacción con el modelo de IA se canaliza mediante el conjunto AI Agent + OpenRouter + Structured Output Parser. El formateador de salida garantiza que el modelo responda bajo una estructura rígida en formato JSON conteniendo exactamente los siguientes campos:

- categoria
- intencion
- prioridad
- lead_score
- requiere_revision
- respuesta

El valor booleano del campo requiere_revision es el detonante que utiliza la lógica del workflow para bifurcar el camino entre una emisión automática o la derivación hacia supervisión humana.

13.3 Prevención de Duplicados

Para prevenir el reprocesamiento de correos electrónicos y la duplicación no deseada de interacciones en el CRM, el flujo utiliza la propiedad única Gmail Message ID proporcionada por el desencadenador de entrada.

El flujo lógico de evaluación de duplicados es el siguiente:

Buscar Interaction por Gmail ID → ¿Ya existe?

Si la búsqueda confirma que el Gmail Message ID ya se encuentra registrado en la tabla Interactions de Airtable, la interacción detiene su flujo normal de procesamiento comercial y es derivada directamente a la gestión de error/excepción.

Este control aporta los siguientes beneficios operativos:

- **Integridad de datos:** Garantiza que cada correo entrante genere exactamente un registro operativo sin duplicar métricas ni historiales.
- **Prevención de duplicados:** Evita que un mismo cliente reciba múltiples respuestas automáticas frente a reenvíos o fluctuaciones del trigger.

- **Eficiencia de proceso:** Cancela inmediatamente la ejecución en etapas tempranas antes de realizar llamadas a servicios externos.
- **Reducción de costos:** Disminuye ejecuciones innecesarias en n8n Cloud y consumo inútil de tokens en OpenRouter.
- **Resiliencia:** Permite recuperar la ejecución o procesar reintentos a nivel de infraestructura sin corromper el estado del sistema.

13.4 Error Handling

El manejo de errores en componentes críticos como modelos de inteligencia artificial o servicios API externos es vital para mantener la continuidad operativa. En este workflow, el nodo AI Agent se encuentra configurado explícitamente con el parámetro:

```
On Error: Continue (using error output)
```

Esta configuración impide la interrupción abrupta del workflow completo ante una falla en la llamada al modelo. Cuando ocurre un evento anómalo (falla en credenciales, indisponibilidad del modelo, time-out), el flujo se desvía hacia una ruta de salida de error dedicada conectada al nodo AI Agent-registrar error en Airtable.

Dicho nodo escribe de forma inmediata un nuevo registro en la tabla dedicada **Errores** en Airtable, capturando los siguientes datos estructurados:

- **Error ID:** Identificador único del fallo.
- **Fecha:** Timestamp exacto de la ocurrencia.
- **Tipo de error:** Categorización técnica de la falla.
- **Nodo:** Nombre específico del nodo donde ocurrió el evento (AI Agent).
- **Workflow:** Identificador o nombre del flujo ejecutor.
- **Mensaje de Error:** Detalle textual devuelto por el sistema/API.
- **Estado:** Estado operativo del incidente para posterior auditoría.

Este mecanismo asegura la conservación total de la trazabilidad y la auditabilidad del sistema frente a eventos fallidos.

13.5 Prueba Real de Error

Con el objetivo de validar empíricamente la robustez de la ruta de manejo de errores, se ejecutó una prueba controlada simulando una falla en el componente de IA (provocando una anomalía relacionada con modelo/credenciales/interconexión).

Resultados de la Prueba de Error

- **Escenario:** Falla provocada en el nodo AI Agent (componente de IA/modelo/credenciales).
- **Comportamiento esperado:** Captura inmediata del fallo mediante On Error: Continue (using error output) sin detener el sistema.
- **Resultado observado:** El flujo fue derivado exitosamente por la ruta alternativa hacia el nodo AI Agent-registrar error en Airtable, creando el correspondiente registro persistente en la tabla *Errores* de Airtable.
- **Evidencia de resiliencia:** Se verificó la detección correcta del error, la no interrupción del entorno de n8n, el desvío a la ruta de contención y la preservación completa de la información del incidente para su revisión técnica posterior.

13.6 Manejo de Entradas Incompletas

Se realizó una prueba empírica evaluando el comportamiento del sistema ante correos con carga útil de información extremadamente reducida o deficiente.

Datos del correo de prueba:

- **Asunto:** “Consulta”
- **Mensaje:** “Hola”

Resultado y Demostración: El workflow no se interrumpió ni generó excepciones no controladas. La consulta mínima avanzó a lo largo de los nodos de evaluación y el AI Agent procesó el mensaje generando una respuesta automática acorde. La prueba demuestra que el workflow posee la resiliencia requerida para tolerar y continuar operando de manera estable ante entradas con información reducida o incompleta.

13.7 Human-in-the-loop (Puntos de Control Humano)

El sistema incorpora una arquitectura de supervisión humana (*Human-in-the-loop*) diseñada para prevenir el envío no supervisado de respuestas en situaciones comerciales delicadas o inciertas.

El punto central de control está determinado por el nodo condicional ¿REQUIERE REVISIÓN HUMANA?, el cual evalúa el parámetro `requiere_revision` emitido por el Structured Output Parser.

¿REQUIERE REVISIÓN HUMANA? → Enviar alerta a Telegram → ¿Aprobar o Desaprobar?

Desglose de Rutas de Supervisión Humana

• Ruta de Aprobación Humana:

Cuando el operador revisa la notificación transmitida por el nodo Enviar alerta a Telegram y selecciona la opción de aprobación en el nodo ¿Aprobar o Desaprobar?:

1. El flujo avanza hacia el nodo Aprobada: Responder, ordenando al servicio Gmail la emisión del correo al cliente.
2. Posteriormente, el nodo Actualizar Interacción - Aprobada persiste el resultado en Airtable guardando los campos:
 - **Estado:** Aprobada y Enviada
 - **Decisión humana:** Aprobada
 - **Respuesta enviada:** Sí

• Ruta de Rechazo Humano:

Si el operador determina que la respuesta propuesta no es adecuada y selecciona el rechazo en ¿Aprobar o Desaprobar?:

1. El flujo se deriva al nodo Registrar decisión: Rechazada.
2. Se actualiza la base de datos registrando formalmente el rechazo operativo.
3. **Garantía de contención:** Se cancela la ejecución del envío, asegurando que *no se envía ninguna respuesta al cliente*.

Pruebas Reales del Mecanismo Human-in-the-loop

El punto de control humano fue probado operacionalmente en ambos escenarios:

- **Prueba de Aprobación:** Se verificó la recepción de la alerta en Telegram, la interacción de aprobación, el envío efectivo del correo por Gmail y el asentamiento en Airtable con estado "Aprobada y Enviada".
- **Prueba de Rechazo:** Se verificó la recepción de la alerta en Telegram, la selección de rechazo, el registro correcto de la decisión en Airtable y la confirmación de ausencia absoluta de envío de correo al cliente.

13.8 Trazabilidad

La trazabilidad integral del sistema se fundamenta en el almacenamiento relacional de eventos a través de tres tablas principales en Airtable:

1. **Leads:** Almacena el registro maestro y perfil del contacto comercial.
2. **Interactions:** Registra la totalidad de las transacciones, correos procesados y decisiones asociadas. La vinculación relacional entre *Leads* e *Interactions* garantiza el histórico completo por cliente.
3. **Errores:** Almacena de manera aislada y detallada las excepciones ocurridas en la ejecución.

Asimismo, en cada transacción se registran y auditan los siguientes atributos: identificador Gmail Message ID, análisis conceptual de la IA, prioridad asignada, lead score, propuesta de respuesta, requerimiento de revisión, decisión del operador humano, confirmación de envío y logs de error.

Estados Relevantes de la Interacción

Para controlar la línea de tiempo operativa, la tabla *Interactions* utiliza los siguientes estados unificados:

- Recibida
- Analizada por IA
- Pendiente aprobación
- Aprobada y Enviada
- Respondida Automaticamente
- Rechazada

14. Matriz de Seguridad y Resiliencia

Riesgo / Situación	Control Implementado	Componente	Resultado
Email duplicado	Evaluación de existencia previa mediante Gmail Message ID	Buscar Interaction por Gmail ID → ¿Ya existe?	Derivación a gestión de error; evita reprocesamiento y envío duplicado
Email irrelevante	Filtro condicional de relevancia de entrada	¿ES CORREO RELEVANTE?	Filtrado temprano de correos no comerciales o irrelevantes
Lead existente	Recuperación de antecedentes comerciales	Buscar Lead en CRM → Recuperación de Historial de Leads	Vinculación al historial previo y contextualización para la IA
Lead nuevo	Alta automática en estructura CRM	Buscar Lead en CRM → Creación de Nuevo Lead	Registro inicial del contacto e interacción aislada

Riesgo / Situación	Control Implementado	Componente	Resultado
Datos incompletos	Tolerancia del modelo e inferencia condicional	AI Agent	Procesamiento continuo sin interrupción del workflow
Error de IA	Ruta de escape y captura de excepciones	On Error: Continue (using error output) → AI Agent-registrar error en Airtable	Captura del fallo y registro persistente en tabla <i>Errores</i>
Revisión humana requerida	Bifurcación condicional basada en salida de IA	¿Requiere revisión humana? → Enviar alerta a Telegram	Detención de respuesta automática y notificación a operador
Aprobación humana	Validación manual afirmativa	¿Aprobar o Desaprobar? → Aprobada: Responder	Envío de correo mediante Gmail y registro "Aprobada y Enviada"
Rechazo humano	Cancelación manual explícita	¿Aprobar o Desaprobar? → Registrar decisión: Rechazada	Registro de rechazo en Airtable y bloqueo absoluto de envío de email

15. Matriz de Error Handling

Situación de Error	Detección	Acción	Registro
Falla en AI Agent (modelo/credenciales/API)	Configuración del nodo AI Agent mediante On Error: Continue (using error output)	Desvío automático por la ruta de salida de error hacia el nodo AI Agent-registrar error en Airtable	Creación de registro en la tabla <i>Errores</i> de Airtable con <i>Error ID</i> , <i>Fecha</i> , <i>Tipo de error</i> , <i>Nodo</i> , <i>Workflow</i> , <i>Mensaje de Error</i> , <i>Estado</i>
Email duplicado recibido	Búsqueda en Airtable mediante Buscar Interaction por Gmail ID y evaluación en ¿Ya existe?	Interrupción de la ruta normal de procesamiento comercial y derivación a gestión de error	Trazabilidad mantenida en el sistema impidiendo duplicaciones en la tabla <i>Interactions</i>

16. Matriz Human-in-the-loop

Punto de Control	Condición	Acción Automática	Acción Humana	Resultado
¿REQUIERE REVISIÓN HUMANA?	TRUE	Ejecuta Enviar alerta a Telegram	Revisión del caso por el operador en Telegram	Espera decisión en nodo ¿Aprobar o Desaprobar?
¿REQUIERE REVISIÓN HUMANA?	FALSE	Ejecuta Enviar respuesta automática y Actualizar Interacción - Respuesta Automática	Ninguna (procesamiento 100% autónomo)	Correo enviado al cliente y registro "Respondida Automaticamente"
¿APROBAR O DESAPROBAR?	TRUE (Aprobar)	Ejecuta Aprobada: Responder (Gmail) y Actualizar Interacción - Aprobada	Selección de opción "Aprobar"	Email enviado por Gmail y registro "Aprobada y Enviada"

Punto de Control	Condición	Acción Automática	Acción Humana	Resultado
¿APROBAR O DESAPROBAR?	FALSE (Desaprobar)	Ejecuta Registrar decisión: Rechazada en Airtable	Selección de opción "Desaprobar"	No se envía correo al cliente; registro con estado "Rechazada"

17. Matriz de Pruebas

Prueba	Escenario	Resultado	Qué Demuestra
Procesamiento de Lead nuevo	Ingreso de correo de remitente no registrado en el CRM	Ejecución de Creación de Nuevo Lead, Registrar Interacción - Nuevo Lead y prosecución del flujo	Correcta ramificación relacional y registro automático de nuevos contactos
Procesamiento de Lead existente	Ingreso de correo de remitente registrado previamente	Ejecución de Recuperación de Historial de Leads, Agrupar Historial y contextualización completa	Correcta vinculación de historial comercial previo para enriquecimiento de IA
Respuesta automática	Evaluación con <code>requiere_revision = false</code>	Ejecución de Enviar respuesta automática y actualización en Airtable	Autonomía de respuesta rápida ante consultas estándares sin riesgo comercial
Aprobación humana	Evaluación con <code>requiere_revision = true</code> y acción afirmativa	Notificación vía Telegram, confirmación manual, emisión vía Gmail y registro "Aprobada y Enviada"	Efectividad de la supervisión humana y correcto flujo de aprobación en canal externo
Rechazo humano	Evaluación con <code>requiere_revision = true</code> y acción negativa	Notificación vía Telegram, rechazo manual, actualización a "Rechazada" y bloqueo de envío	Capacidad de contención absoluta frente a respuestas no deseadas o riesgosas
Datos incompletos	Correo entrante con Asunto: "Consulta" y Mensaje: "Hola"	Procesamiento completo sin interrupción y generación de respuesta automática	Tolerancia a fallos y resiliencia del flujo frente a insumos informativos mínimos
Error de IA	Falla provocada en el nodo AI Agent (modelo/credenciales)	Captura por On Error: Continue y registro del incidente en tabla <i>Errores</i>	Estabilidad de la infraestructura y trazabilidad de fallos en tiempo de ejecución

18. Cumplimiento del Criterio de Seguridad y Resiliencia

Criterio de la Rúbrica	Implementación	Evidencia
Minimización de datos	Exclusión de identificadores internos de n8n/Airtable en el prompt enviado al AI Agent; envío únicamente del contenido estrictamente necesario para el análisis comercial.	Estructura de prompt depurada, reducción medida del consumo de tokens y tabla de mapeo de campos auditada.

Criterio de la Rúbrica	Implementación	Evidencia
Rutas de error / Error Handling	Configuración On Error: Continue (using error output) en el nodo AI Agent conectada al nodo AI Agent-registrar error en Airtable. Prevención de duplicación por Gmail Message ID.	Prueba empírica de error provocada en IA con registro verificado en la tabla <i>Errores</i> de Airtable. Desvío comprobado de duplicados.
Human-in-the-loop points	Bifurcación condicional basada en el parámetro <code>requiere_revision</code> emitido por el Structured Output Parser, integrada a Telegram para aprobación/rechazo previo al envío por Gmail.	Pruebas operacionales validadas en escenarios reales de Aprobación (envío efectuado) y Rechazo (envío bloqueado).

Justificación de Cumplimiento

El proyecto **AI Sales & Customer Operations Agent** satisface íntegramente los tres pilares de la rúbrica mediante controles técnicos ejecutables:

1. **Minimización de datos:** Cumplida mediante la selección consciente de variables y la eliminación de metadatos/IDs del prompt, protegiendo la topología interna y reduciendo costos de tokens.
2. **Rutas de error / Error Handling:** Cumplida al garantizar que ninguna excepción en la IA provoque la caída estruendosa del flujo, ofreciendo una ruta alternativa de contención y persistencia en Airtable.
3. **Human-in-the-loop points:** Cumplida al instaurar un punto de control humano previo al envío de correos sensibles, garantizando que el sistema operativamente responda solo bajo supervisión explícita cuando la condición así lo exija.

19. Conclusión

El desarrollo e implementación del workflow **AI Sales & Customer Operations Agent** demuestra la integración práctica y rigurosa de controles de seguridad y resiliencia en arquitecturas de automatización basadas en Inteligencia Artificial. La solución no se limita a ejecutar tareas autónomas, sino que establece un marco operativo seguro mediante:

- La minimización estricta de la información expuesta hacia modelos externos de IA.
- La prevención proactiva de interacciones duplicadas mediante la validación del Gmail Message ID.
- La definición de rutas condicionales para la diferenciación del tratamiento según el perfil y estado del Lead.
- La implementación de mecanismos explícitos de tolerancia a fallos mediante el aislamiento y registro sistemático de errores en la tabla *Errores* de Airtable.
- La trazabilidad completa del ciclo de vida de cada interacción a través de estados bien definidos.
- La incorporación efectiva de supervisiones humanas (*Human-in-the-loop*) antes de la emisión de comunicaciones sensibles.
- La ejecución de pruebas empíricas reales sobre escenarios normales, anómalos (errores de IA), límites (datos incompletos) y de supervisión (aprobación/rechazo).

En conclusión, el documento certifica un sistema resiliente, trazable y supervisado, alineado de manera precisa con las especificaciones técnicas y académicas exigidas por la rúbrica de evaluación.